IMPLEMENTASI RETRIEVAL-AUGMENTED GENERATION (RAG) DENGAN GENERATOR QWEN 2.5 7B INSTRUCT PADA SISTEM TANYA JAWAB STUNTING

Muhammad Andrata[1], Irfan Maliki[2]

[1,2] Universitas Komputer Indonesia
Jalan Dipatiukur No. 112-116, Coblong, Kota Bandung, Jawa Barat 40132.
E-mail : andrata2908@gmail.com[1], irfan.maliki@email.unikom.ac.id[2]

Abstrak

Stunting merupakan permasalahan gizi kronis yang masih menjadi isu kesehatan masyarakat serius di Indonesia, dengan prevalensi nasional 19,8% pada tahun 2024. Meskipun berbagai program intervensi telah dijalankan, pengetahuan masyarakat terhadap stunting masih rendah, tercermin dari hanya 1,7% responden nasional yang memiliki pengetahuan dan sikap baik. Large Language Models (LLM) menawarkan peluang sebagai sistem tanya jawab interaktif untuk menjembatani kesenjangan informasi tersebut, namun implementasinya masih dibatasi oleh hallucination dan knowledge cut-off. Retrieval-Augmented Generation (RAG) diusulkan sebagai solusi dengan mengintegrasikan pengambilan informasi dari sumber eksternal yang faktual sebelum model menghasilkan jawaban. Penelitian ini mengimplementasikan pipeline RAG menggunakan generator Qwen 2.5 7B Instruct terkuantisasi NF4 4-bit, didukung knowledge base 60 dokumen resmi yang diindeks menjadi 12.558 chunk melalui FAISS. Pengujian pada Gold Standard Dataset menunjukkan kinerja retrieval kuat dengan rata-rata MRR 0,9469 dan Context Precision 0,9565, serta kinerja generation dengan rata-rata Faithfulness 0,8988 dan Answer Relevancy 0,9223. Hasil ini membuktikan RAG signifikan mengurangi hallucination dibanding No-RAG, yang gagal total pada pertanyaan numerik dengan relevansi 0%, meskipun tantangan hallucination tetap ditemukan pada data numerik dengan Faithfulness turun hingga 68,75%. Penerapan arsitektur RAG terbukti mampu mengoptimalkan model bahasa skala kecil untuk menghasilkan jawaban kredibel, relevan, dan berbasis bukti faktual bagi edukasi stunting di Indonesia.

Kata kunci : Retrieval-Augmented Generation, Qwen 2.5 7B, Stunting, LLM Hallucination, Sistem Tanya Jawab.

Abstract

Stunting is a chronic nutritional problem that remains a serious public health issue in Indonesia, with a national prevalence of 19.8% in 2024. Although various intervention programs have been implemented, public knowledge about stunting remains low, reflected in only 1.7% of national respondents having good knowledge and attitudes. Large Language Models (LLMs) offer an opportunity as interactive question-answering systems to bridge this information gap, but their implementation is still limited by hallucination and knowledge cut-off. Retrieval-Augmented Generation (RAG) is proposed as a solution by integrating the retrieval of factual information from external sources before the model generates an answer. This study implements a RAG pipeline using a Qwen 2.5 7B Instruct generator quantized with NF4 4-bit, supported by a knowledge base of 60 official documents indexed into 12,558 chunks through FAISS. Testing on the Gold Standard Dataset shows strong retrieval performance with an average MRR of 0.9469 and Context Precision of 0.9565, along with generation performance averaging 0.8988 Faithfulness and 0.9223 Answer Relevancy. These results demonstrate that RAG significantly reduces hallucination compared to No-RAG, which failed completely on numerical questions with 0% relevance, although hallucination challenges remain for numerical data, with Faithfulness dropping to as low as 68.75%. The application of the RAG architecture proves capable of optimizing small-scale language models to produce credible, relevant answers grounded in factual evidence for stunting education in Indonesia.

Keywords : *Retrieval-Augmented Generation, Qwen 2.5 7B, Stunting, LLM Hallucination, Question Answering System.*

1. PENDAHULUAN

Stunting adalah kondisi gagal tumbuh kembang pada anak akibat kekurangan gizi kronis dan infeksi berulang, dan hingga kini tetap menjadi masalah kesehatan masyarakat yang serius di Indonesia [1]. Selain menghambat pertumbuhan fisik dan memicu gangguan metabolik di masa dewasa, stunting menurunkan kemampuan kognitif anak serta menimbulkan kerugian ekonomi nasional hingga 2–3% dari Produk Domestik Bruto setiap tahunnya [1]. Survei Status Gizi Indonesia (SSGI) 2024 mencatat prevalensi stunting nasional sebesar 19,8%, turun dari 21,6% pada 2022, namun masih di atas target pemerintah sebesar 14% [2]. Data yang sama menunjukkan penyebab stunting bersifat multidimensi, mencakup gizi ibu, infeksi berulang, kualitas MP-ASI, akses sanitasi, hingga kondisi pendidikan dan ekonomi keluarga [2].

Upaya pemerintah menekan angka tersebut melalui intervensi yang diatur dalam Perpres No. 72 Tahun 2021 masih terkendala pada keterbatasan jumlah dan kapasitas kader posyandu serta jangkauan program yang belum merata [1]. Akibatnya, pengetahuan masyarakat terhadap stunting masih rendah, SSGI 2024 mencatat hanya 1,7% responden nasional yang memiliki pengetahuan dan sikap baik terhadap stunting [2], sejalan dengan temuan bahwa 50,3% remaja putri belum pernah terpapar informasi stunting dari sumber yang memadai [3]. Kesenjangan ini menegaskan perlunya kanal edukasi mandiri yang dapat menjangkau masyarakat tanpa sepenuhnya bergantung pada kapasitas kader.

Perkembangan *Natural Language Processing* (NLP) dan *Large Language Models* (LLM) membuka peluang membangun sistem tanya jawab interaktif yang mampu menjembatani kesenjangan informasi tersebut [4], [5], dengan antarmuka percakapan yang lebih manusiawi dan dapat diakses langsung oleh masyarakat [5], [6]. Namun, penerapan LLM di domain kesehatan masih dibatasi oleh masalah *hallucination* dan *knowledge cut-off* [7], [8], [9], LLM dapat menghasilkan jawaban yang terdengar meyakinkan namun tidak akurat karena bergantung pada pola statistik bahasa, bukan pengetahuan yang terverifikasi [10], [11], risiko yang serius pada domain medis seperti stunting karena berpotensi memengaruhi keselamatan dan pengambilan keputusan kesehatan [7], [12].

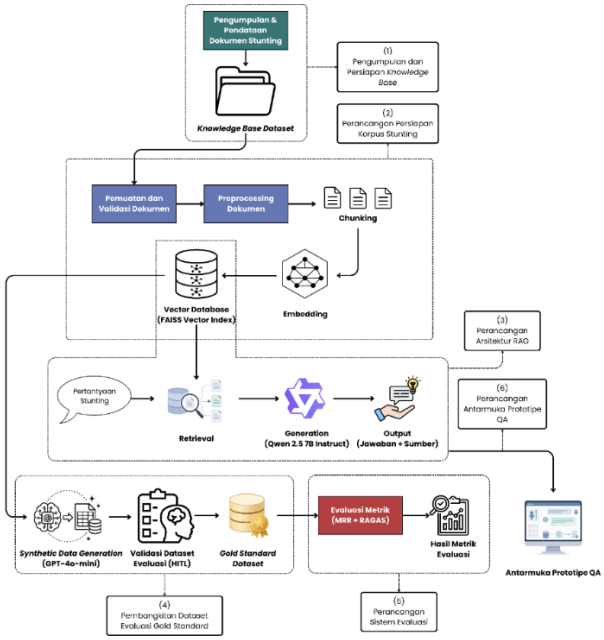
Retrieval-Augmented Generation (RAG) menjawab keterbatasan tersebut dengan mengintegrasikan pengambilan informasi dari sumber eksternal yang faktual sebelum LLM menghasilkan respons [13], [14], [15], sehingga menekan *hallucination* dan menjamin jawaban tetap berbasis data valid [13], [16]. Pendekatan ini terbukti efektif di domain kesehatan, RAG pada tugas pemahaman pengetahuan medis meningkatkan skor evaluasi rata-rata hingga 3,86% dibanding model dasar [15], sementara integrasi graf pengetahuan ke dalam RAG mendorong skor ROUGE-1 naik hingga 9,72% pada tugas *multi-hop question answering* [14]. Di luar domain kesehatan, RAG juga terbukti menjaga relevansi dan akurasi kontekstual, misalnya pada sistem penilaian berbasis LLM di pendidikan tinggi [17], yang mengindikasikan potensi penerapannya pada domain kesehatan seperti stunting. Temuan ini mendukung rekomendasi agar LLM dalam domain kesehatan memanfaatkan korpus yang sesuai sebagai basis pengetahuan, selaras dengan regulasi dan praktik yang berlaku [10].

Meski potensinya besar [4], [14], [15], penelitian RAG untuk domain stunting berbahasa Indonesia masih minim, karena sebagian besar riset RAG masih berpusat pada model berbahasa Barat, representasi Bahasa Indonesia pada LLaMA-2 misalnya hanya 0,03% dari total data pra-pelatihan, dengan kesenjangan performa hingga 20% weighted F1-score dibanding model yang dioptimalkan khusus [18], [19]. Untuk mengisi kesenjangan tersebut, penelitian ini menggunakan model Qwen 2.5 7B Instruct, yang dipilih atas dasar aksesibilitas dan efisiensi deployment, kebutuhan komputasinya lebih rendah sehingga realistis dijalankan pada perangkat keras terjangkau di institusi kesehatan daerah [20], [21], tanpa mengorbankan kapabilitas bahasa karena Qwen 2.5 mahir dalam sekitar 30 bahasa termasuk Bahasa Indonesia [20], [22] dan mencatat skor 92,2 pada evaluasi *LLM-as-a-Judge* untuk tugas RAG berbahasa Indonesia [23].

Tujuan penelitian ini adalah mengimplementasikan pipeline RAG berbasis dokumen stunting berbahasa Indonesia, mulai dari persiapan korpus, pembangunan representasi vektor, hingga integrasi dengan model Qwen 2.5 7B Instruct sebagai mesin generasi jawaban serta menganalisis kinerjanya secara empiris melalui kerangka evaluasi terstruktur, untuk membuktikan sejauh mana augmentasi RAG meningkatkan kualitas respons model skala kecil sebagai landasan pengembangan sistem serupa di masa mendatang [4], [24].

2. METODOLOGI

Penelitian ini menerapkan pendekatan kuantitatif eksperimental yang diorganisasikan ke dalam enam tahap perancangan sistem: 1) Pengumpulan dan persiapan knowledge base stunting; 2) Perancangan persiapan korpus stunting; 3) Perancangan arsitektur RAG; 4) Pembangkitan dataset evaluasi Gold Standard; 5) Perancangan sistem evaluasi; dan 6) Perancangan antarmuka prototipe QA berbasis Gradio. Alur kerja end-to-end ini menggunakan library orkestrator LangChain pada lingkungan Google Colaboratory dengan akselerasi GPU NVIDIA Tesla T4 (16 GB VRAM). Alur kerja end-to-end ini digambarkan pada Gambar 1.



Gambar 1. Diagram End-to-End RAG Stunting

2.1 Pengumpulan dan Persiapan Knowledge Base

Basis pengetahuan (*knowledge base*) dibangun secara selektif dengan mengumpulkan korpus dokumen terkait stunting yang diterbitkan dalam rentang tahun 2014 hingga 2026 dari sumber-sumber instansi resmi yang kredibel, seperti Kementerian Kesehatan RI (Kemenkes), BKKBN, Kemendes PDTT, Setwapres, serta beberapa pemerintah daerah dan repositori jurnal ilmiah terakreditasi. Dari proses kurasi tersebut, diperoleh sebanyak 60 dokumen heterogen yang dikelompokkan ke dalam 5 tingkatan kredibilitas sesuai jenis dokumen yang berdasarkan otoritas regulasi dan hukum di Indonesia. Distribusi jenis dokumen dalam basis pengetahuan ditunjukkan secara rinci pada Tabel 1.

Tabel 1. Distribusi knowledge base berdasarkan jenis dokumen

Jenis Dokumen	Jumlah	Cakupan Dokumen
Regulasi Nasional	11	Regulasi Nasional (Perpres, Permenkes, UU)
Panduan Teknis	19	Panduan Teknis Resmi Kementerian/Lembaga
Data Pemerintah	16	Data Kuantitatif/Kualitatif atau Dokumen Strategi
Regulasi Daerah	6	Regulasi Daerah (Pergub, Perbup, SK Kepala Daerah)
Jurnal Ilmiah	8	Jurnal Ilmiah Terverifikasi (Sinta/Scopus)
Total	**60**	**-**

Seluruh dokumen *knowledge base* diklasifikasikan dan disimpan dalam direktori terpusat, serta diregistrasikan ke dalam berkas metadata verified_documents_metadata.json yang bertindak sebagai *single source of truth*. Dari 60 dokumen, sebanyak 48 berkas merupakan PDF asli dari penerbit, 8 berkas berformat Markdown (.md) hasil konversi dari PDF yang didominasi tabel rumit menggunakan pustaka *marker*, dan 4 berkas berformat DOCX hasil konversi data kuantitatif dari spreadsheet (Excel) ke bentuk kalimat naratif terstruktur.

2.2 Perancangan Persiapan Korpus Stunting

Setelah dokumen diverifikasi, korpus dialirkan melalui *data pipeline* yang terdiri atas empat tahap berurutan. Tahap pertama adalah pemuatan dokumen yang dirancang secara *format-aware*, di mana PDF berhalaman digital diekstraksi menggunakan PyMuPDF, halaman hasil pindai ditangani melalui OCR Tesseract sebagai jalur *fallback*, dokumen Word diproses melalui *DOCX XML parser* yang mengiterasi

elemen *body* dokumen secara langsung sehingga urutan konten asli tetap terjaga, sedangkan dokumen Markdown ditangani oleh *custom block parser*. Tahap kedua adalah *preprocessing* teks yang dirancang untuk membersihkan derau semantik, mencakup pembersihan khusus PDF berupa penghapusan watermark URL instansi melalui *regex* serta normalisasi *line-break* fisik hasil ekstraksi PyMuPDF, dan pembersihan universal berupa eliminasi tag HTML sisa konversi, normalisasi karakter ligatur, serta penyisipan spasi antara angka dan satuan gizi seperti "6bulan" menjadi "6 bulan". Pada tahap ini pula dilakukan penyaringan konten struktural nonsubstantif seperti Daftar Isi dan Daftar Pustaka menggunakan kombinasi sinyal *dotted leader*, akhiran angka, dan *keyword anchor*, sehingga dokumen struktural tersebut tidak ikut bersaing pada hasil *retrieval*.

Tahap ketiga adalah *chunking*, yang memecah dokumen menjadi segmen teks siap-*embed* melalui dua jalur sesuai karakteristik kontennya sebagaimana dirangkum pada Tabel 2.

Tabel 2. Konfigurasi strategi chunking

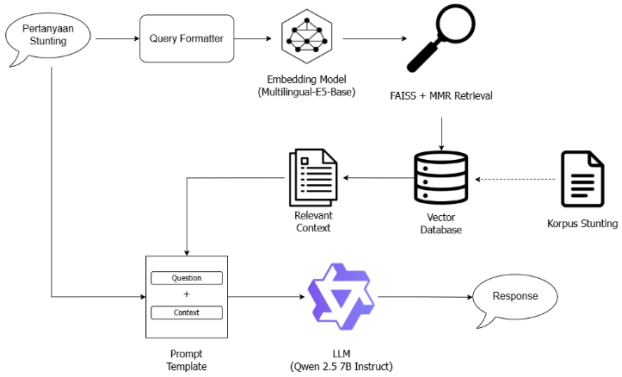
Jalur Konten	Metode	Ukuran Chunk	Overlap
Teks Naratif	RecursiveCharacterTextSplitter	1.000 karakter	200 karakter
Data Tabular	Row-based Semantic Splitting	1.200 karakter	2 baris

Pada jalur tabular, baris tabel dikonversi secara serial menjadi kalimat deklaratif terstruktur berformat "[Konteks: Nama Tabel] Kolom1: Nilai | Kolom2: Nilai" guna mempertahankan relasi semantik antar-data medis. Setelah dokumen dipecah melalui jalurnya masing-masing, seluruh *chunk* dikumpulkan untuk melewati tujuh tahapan filter dan optimasi berurutan, yaitu penghapusan *noise* berupa *chunk* kosong atau artefak *syntax*, penyapuan sisa komponen struktural yang lolos dari lapisan *preprocessing* awal, injeksi konteks berupa penyisipan kalimat induk pada *chunk* yang berisi butir *list* agar tidak kehilangan makna saat dipanggil terpisah, penggabungan *chunk* pendek dari halaman yang sama untuk menjaga kerapatan informasi, penyaringan *chunk* yang tetap berada di bawah batas minimum panjang setelah proses penggabungan, deduplikasi yang hanya mempertahankan *chunk* dari dokumen dengan tingkat kredibilitas tertinggi, serta injeksi metadata berupa penyisipan judul dan sumber dokumen ke bagian awal teks *chunk*. Penerapan metadata yang ketat pada tahap ini terbukti penting untuk ketepatan *retrieval* dalam sistem tanya-jawab [25].

Tahap keempat adalah *embedding* dan pengindeksan. Setiap *chunk* final diberi prefiks "passage: " sebelum dikonversi menjadi representasi vektor menggunakan model *intfloat/multilingual-e5-base* [26], sesuai format masukan yang disyaratkan model E5 untuk membedakan representasi dokumen dari representasi *query* pengguna. Model menghasilkan vektor berdimensi 768 dengan panjang norma ternormalisasi ($\|v\| = 1$), sehingga pengukuran jarak Euclidean pada struktur indeks *IndexFlatL2* dari pustaka FAISS menjadi ekuivalen secara matematis dengan *cosine distance*. Seluruh vektor beserta metadata dokumen asalnya disimpan ke dalam *vector store* FAISS yang menjadi korpus stunting terindeks untuk digunakan pada tahap perancangan arsitektur RAG selanjutnya.

2.3 Perancangan Arsitektur RAG

Setelah tahap persiapan korpus menghasilkan indeks FAISS yang siap digunakan sebagai sumber jawaban, tahap selanjutnya adalah merancang arsitektur RAG yang bertugas melayani pertanyaan pengguna secara *real-time*. Arsitektur ini merupakan lapisan inferensi sistem yang bekerja dengan mengintegrasikan dua komponen utama, yaitu komponen *retrieval* dan komponen *generation*, sebagaimana diilustrasikan pada Gambar 2.



Gambar 2. Gambaran Umum Pipeline RAG Stunting.

Secara umum, alur kerja pipeline dimulai ketika pengguna mengajukan pertanyaan seputar stunting. Pertanyaan tersebut terlebih dahulu diformat oleh *query formatter* dengan diberi prefiks "query: " sebelum dikonversi menjadi representasi vektor oleh model *embedding multilingual-e5-base* yang sama dengan tahap pengindeksan, karena model tersebut mensyaratkan format masukan yang berbeda antara teks dokumen dan teks pertanyaan agar keduanya berada pada ruang representasi yang sebanding. Representasi vektor ini kemudian digunakan untuk melakukan pencarian semantik pada indeks FAISS guna memperoleh sejumlah kandidat segmen dokumen yang relevan, yang selanjutnya diseleksi menggunakan algoritma *Maximal Marginal Relevance* (MMR) untuk menyeimbangkan relevansi terhadap pertanyaan dengan keberagaman antar dokumen yang diambil, sehingga mengurangi redundansi konteks yang dikirim ke LLM dibandingkan pendekatan *pure similarity search* [27]. Segmen dokumen hasil MMR masih membawa prefiks "passage: " dari tahap pengindeksan sehingga dibersihkan terlebih dahulu sebelum diteruskan ke tahap generasi, dengan dua jalur pengambilan yang disesuaikan kebutuhannya, yaitu jalur antarmuka *chatbot* yang hanya mengembalikan konten bersih tanpa metadata tambahan, dan jalur evaluasi yang menyertakan metadata lengkap beserta skor kemiripan untuk perhitungan metrik MRR dan RAGAS pada tahap pengujian.

Pada komponen *generation*, pertanyaan pengguna digabungkan bersama konteks hasil *retrieval* ke dalam *prompt template* terstruktur mengikuti format ChatML sesuai konvensi model Qwen, yang terdiri atas *system message* dengan enam blok instruksi, yaitu identitas StuntBot, konteks domain stunting, larangan keras menyebut metadata teknis atau menggunakan frasa *self-referential* seperti "berdasarkan dokumen di atas", larangan temporal terhadap kata ambigu seperti "saat ini" atau "sekarang", aturan penolakan terhadap pertanyaan di luar domain stunting, serta aturan penulisan kalimat pembuka yang langsung menjawab inti pertanyaan. *Prompt* yang telah tersusun kemudian diserahkan kepada model Qwen 2.5 7B Instruct untuk menghasilkan respons akhir, yang dijalankan menggunakan teknik kuantisasi *Normal Float* 4-bit (NF4) melalui pustaka *bitsandbytes* untuk mereduksi beban memori VRAM GPU Tesla T4. Seluruh konfigurasi parameter pada kedua komponen dirangkum pada Tabel 3. Dari hasil eksperimen terbukti bahwa kuantisasi NF4 4-bit mengurangi ukuran model hingga 64,3% dan menekan kebutuhan VRAM puncak hingga 56,0% tanpa mengorbankan kualitas substansi jawaban, sehingga memberi ruang bagi komponen embedding dan proses retrieval untuk berjalan bersamaan pada GPU T4 berkapasitas 16 GB.

Tabel 3. Konfigurasi parameter komponen retrieval dan generation

Komponen	Parameter	Nilai
Retrieval	k	5
Retrieval	fetch_k	30
Retrieval	lambda_mult	0,85
Generation	temperature	0,1
Generation	max_new_tokens	1.024
Generation	top_p	0,95
Generation	repetition_penalty	1,05

2.4 Pembangkitan Dataset Evaluasi Gold Standard

Untuk mengukur kinerja sistem secara objektif, dataset standar emas (*Gold Standard Dataset*) dibangun otomatis menggunakan *synthetic data generation* (SDG) dengan GPT-4o-mini sebagai generator melalui OpenRouter API, dengan paradigma *generate-then-filter*. Kandidat pertanyaan-jawaban-konteks dibangkitkan dari 2.714 *chunk* unik yang telah melewati filter pra-generasi, lalu divalidasi melalui tiga lapis otomatis berupa validasi skema JSON, *groundedness check* untuk mendeteksi halusinasi jawaban, dan *Round-Trip Consistency* untuk memastikan *chunk* sumber dapat ditemukan kembali oleh *retriever* pada *top-5*. Proses dihentikan setelah terkumpul 80 pasang QA yang terdistribusi pada enam tipe pertanyaan, yaitu 24 *factual*, 18 *causal*, 14 *procedural*, 10 *multi-context*, 8 *numerical*, dan 6 *policy*.

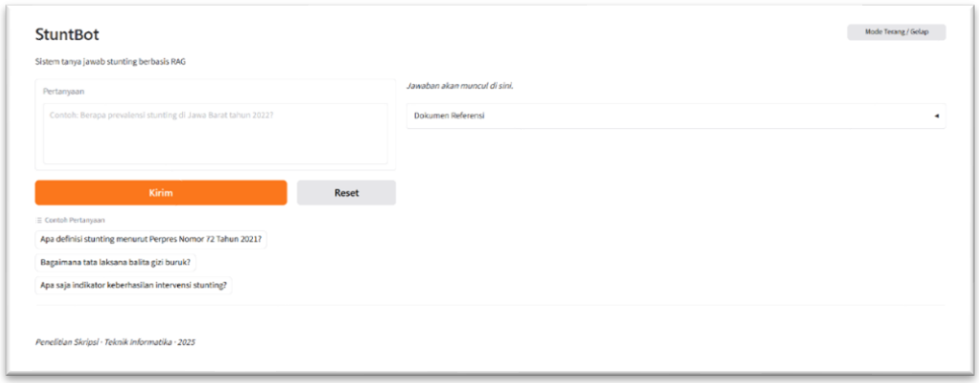
Dataset otomatis ini selanjutnya dialirkan ke pipeline validasi manual berbasis *Human-in-the-Loop* (HITL) untuk menjaga akurasi dan akuntabilitas [17], dengan melibatkan dua evaluator. Peneliti (Evaluator 1) mengukur *Source Groundedness* antara jawaban dan *chunk* sumber di indeks FAISS, sementara Pakar Gizi (Evaluator 2) memvalidasi kebenaran medis dan kejelasan linguistik pada tiga dimensi, yaitu *Faithfulness*, *Answer Consistency*, dan *Clarity*, dengan skala 1 hingga 3. Pasangan QA berskor 1 pada *Faithfulness* atau *Answer Consistency* ditolak dan dibangkitkan ulang, skor 2 pada salah satu dimensi direvisi, dan skor 3 pada seluruh dimensi diterima penuh. Iterasi ini menghasilkan 80 pasang QA final berkualitas tinggi sebagai acuan tunggal evaluasi sistem.

2.5 Perancangan Sistem Evaluasi

Sistem evaluasi menilai pipeline dari dua aspek. Komponen *retrieval* dievaluasi menggunakan MRR untuk menilai peringkat dokumen relevan, serta dua metrik RAGAS yaitu *Context Precision* yang mengukur kebersihan hasil retrieval dari *chunk* tidak relevan, dan *Context Recall* yang mengukur kelengkapan informasi terhadap *ground truth*. Komponen *generation* dievaluasi menggunakan tiga metrik RAGAS yaitu *Faithfulness* yang mengukur konsistensi faktual jawaban terhadap konteks, *Answer Relevancy* yang mengukur ketepatan sasaran jawaban terhadap pertanyaan, dan *Answer Correctness* yang mengukur keakuratan jawaban terhadap *ground truth* pakar. Perhitungan metrik RAGAS menggunakan GPT-4o-mini sebagai *judge model* [28]. Selain itu, dilakukan evaluasi komparatif antara skenario RAG penuh dan No-RAG pada 80 pertanyaan yang sama untuk mengukur kontribusi *retrieval* dalam mereduksi halusinasi.

2.6 Perancangan dan Realisasi Antarmuka Prototipe QA

Sebagai validasi fungsionalitas pipeline dalam skenario interaksi pengguna nyata, sistem direalisasikan sebagai aplikasi web satu halaman menggunakan kerangka kerja Gradio. Antarmuka terbagi menjadi kolom input pertanyaan beserta contoh pertanyaan di sebelah kiri, dan kolom keluaran jawaban di sebelah kanan yang dilengkapi panel dokumen referensi *(expandable panel)* untuk menampilkan judul, sumber, tahun, nomor halaman, serta skor kemiripan setiap dokumen yang diambil, sebagai bentuk transparansi sumber jawaban kepada pengguna. Tampilan awal antarmuka prototipe ditunjukkan pada Gambar 3.



Gambar 3. Tampilan awal antarmuka prototipe QA.

3. HASIL DAN PEMBAHASAN

3.1 Analisis Kinerja Komponen Retrieval

Kinerja komponen *retrieval* diukur untuk memastikan seberapa efektif sistem menemukan dokumen pendukung yang relevan dari database FAISS berisi 12.558 *chunk*. Pengujian pada 80 pertanyaan menghasilkan nilai rata-rata *MRR* sekitar 0,95, *Context Precision* sekitar 0,96, dan *Context Recall* sekitar 0,87. Rincian performa berdasarkan tipe pertanyaan disajikan pada Tabel 4.

Tabel 4. Rincian kinerja komponen retrieval berdasarkan tipe pertanyaan

Tipe Pertanyaan	Jumlah (n)	MRR (Mean)	Context Precision	Context Recall
Factual	24	0,9375	0,9608	0,8757
Causal	18	0,9444	0,9836	0,9213
Procedural	14	0,9107	1,0000	0,9524
Multi-context	10	1,0000	1,0000	0,8250
Numerical	8	0,9375	0,7505	0,7500
Policy	6	1,0000	0,9593	0,7778
Agregat Keseluruhan	**80**	**0,9469**	**0,9565**	**0,8731**

Sistem mencatat *hit rate retrieval* sebesar 100%, di mana tidak ada satu pun pertanyaan yang gagal menemukan dokumen relevan di dalam peringkat *top-5*. Sebagian besar pertanyaan (90%) berhasil menempatkan dokumen relevan tepat di peringkat pertama. Tipe *multi-context* dan *policy* meraih skor *MRR* sempurna, yang mengonfirmasi bahwa dokumen kebijakan dan sumber lintas-konteks memiliki representasi vektor yang sangat distingtif dalam indeks FAISS sehingga sangat mudah dikenali oleh model *embedding*.

Di sisi lain, tipe pertanyaan *numerical* mencatat kinerja terendah dengan *Context Precision* dan *Context Recall* yang sama-sama berada di kisaran 0,75. Penurunan ini disebabkan oleh karakteristik data tabular stunting, seperti tabel angka prevalensi balita per provinsi, yang setelah melewati *row-based semantic splitting* menghasilkan banyak *chunk* pendek dengan konten angka yang hampir serupa. Algoritma *MMR* mengidentifikasi kemiripan semantik yang tinggi antar-*chunk* angka tersebut sebagai redundansi, sehingga menyisihkan sebagian *chunk* data numerik penting dari daftar *top-5* hasil dan memicu hilangnya sebagian konteks yang dibutuhkan untuk menjawab pertanyaan numerik secara komprehensif.

3.2 Analisis Kinerja Komponen Generation

Kinerja komponen *generation* mengukur kualitas respons model Qwen 2.5 7B Instruct saat menerima augmentasi konteks *retrieval*. Hasil pengujian agregat mencatat nilai rata-rata *Faithfulness* sekitar 0,90, *Answer Relevancy* sekitar 0,92, dan *Answer Correctness* sekitar 0,73. Distribusi metrik *generation* berdasarkan tipe pertanyaan ditunjukkan pada Tabel 5.

Tabel 5. Rincian kinerja komponen generation berdasarkan tipe pertanyaan

Tipe Pertanyaan	Jumlah (n)	Faithfulness	Answer Relevancy	Answer Correctness
Factual	24	0,9493	0,9120	0,7340
Causal	18	0,9114	0,9292	0,7798
Procedural	14	0,8751	0,9362	0,7424
Multi-context	10	0,8964	0,9067	0,7120
Numerical	8	0,6875	0,9442	0,6646
Policy	6	1,0000	0,9075	0,6466
Agregat Keseluruhan	**80**	**0,8988**	**0,9223**	**0,7295**

Answer Relevancy merupakan metrik dengan sebaran paling konsisten dan rapat di antara ketiganya, menandakan bahwa sistem hampir selalu mampu menjawab langsung ke inti pertanyaan tanpa menghasilkan informasi bertele-tele yang melenceng. Tipe *policy* mencatatkan *Faithfulness* sempurna, karena gaya bahasa regulasi yang bersifat formal, normatif, dan tegas mendorong model untuk melakukan kutipan langsung secara literal tanpa menambahkan opini atau inferensi tambahan di luar teks.

Sebaliknya, tipe *numerical* menjadi titik kelemahan kritis utama pada komponen *generation*, dengan nilai rata-rata *Faithfulness* terendah di kisaran 0,69. Terdapat dua pertanyaan numerik yang mencatat *Faithfulness* 0%, yang berarti seluruh klaim angka di dalam respons model terbukti salah atau tidak ada dalam konteks. Kondisi ini berkorelasi kuat dengan rendahnya nilai *Context Recall* pada tipe numerik. Ketika *retriever* gagal menyajikan segmen data tabel angka secara lengkap akibat *pruning MMR*, model bahasa berparameter kecil cenderung mengisi celah informasi kosong tersebut dengan berhalusinasi menggunakan angka dari memori parametrik internalnya. Hasil analisis membuktikan pada konteks stunting, RAG andal mereduksi halusinasi pada konten berbasis naratif-konseptual, namun masih rentan mengalami kegagalan pada konten tabular berbasis angka.

3.3 Evaluasi Komparatif Kinerja RAG vs No-RAG

Untuk membuktikan kontribusi nyata dari augmentasi komponen *retrieval*, dilakukan pengujian komparatif dengan mengalirkan 80 pertanyaan yang sama langsung ke model Qwen 2.5 7B Instruct tanpa bantuan mekanisme *retrieval*. Perbandingan dibatasi pada metrik *Answer Relevancy* (AR) dan *Answer Correctness* (AC) karena keduanya tidak membutuhkan input konteks dalam penghitungannya. Hasil perbandingan per tipe pertanyaan disajikan pada Tabel 6.

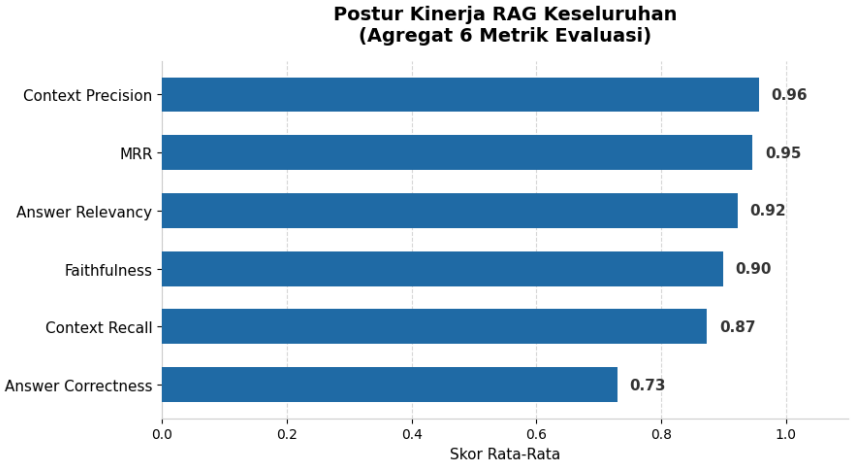
Tabel 6. Perbandingan kinerja metrik generasi antara skenario RAG dan No-RAG

Tipe	AR RAG	AR No-RAG	Selisih AR	AC RAG	AC No-RAG	Selisih AC
Factual	0,9120	0,8084	+0,1036	0,7340	0,5917	+0,1423
Causal	0,9292	0,8597	+0,0695	0,7798	0,6383	+0,1415
Procedural	0,9362	0,8433	+0,0929	0,7424	0,4444	+0,2980
Multi-context	0,9067	0,9035	+0,0032	0,7120	0,6416	+0,0704
Numerical	0,9442	0,0000	+0,9442	0,6646	0,2210	+0,4436
Policy	0,9075	0,4527	+0,4548	0,6466	0,4481	+0,1985
Agregat	**0,9223**	**0,7304**	**+0,1919**	**0,7295**	**0,5348**	**+0,1947**

Berdasarkan Tabel 6, penerapan RAG memberikan peningkatan kinerja rata-rata yang konsisten dan signifikan, di mana *Answer Relevancy* meningkat sekitar 19% dan *Answer Correctness* meningkat sekitar 19% juga. Tiga pola paling menonjol dapat diidentifikasi dari perbandingan ini. Pertama, pada tipe *numerical*, skenario *No-RAG* mencatat *Answer Relevancy* 0% pada seluruh pertanyaan uji, membuktikan bahwa model bahasa umum tidak memiliki kapasitas ingatan parametrik terhadap data statistik prevalensi stunting lokal dan persentase program kesehatan di Indonesia, sehingga penolakan atau kegagalan total terjadi tanpa RAG. Dengan RAG, relevansi melonjak tajam ke atas 90%. Kedua, pada tipe *policy*, *No-RAG* mencatat AR hanya sekitar 45% karena regulasi daerah seperti Pergub NTT atau Pergub Papua Barat bersifat sangat *domain-specific* dan tidak pernah dijumpai model saat fase *pre-training* umum. RAG mengoreksi keterbatasan ini dengan meningkatkan AR menjadi sekitar 91%.

Pola ketiga terlihat pada tipe *procedural*, di mana selisih *Answer Relevancy* antara RAG dan *No-RAG* hanya sekitar 9%, namun selisih *Answer Correctness* mencapai hampir 30%. Analisis kualitatif terhadap jawaban model *No-RAG* menunjukkan bahwa model tanpa *retrieval* mampu menyusun kalimat jawaban prosedural yang terdengar sangat meyakinkan, runtut, dan terstruktur sebagai langkah-langkah medis. Namun, ketika dicocokkan dengan standar operasional prosedur resmi Kemenkes, substansi langkah gizi tersebut terbukti salah dan menyesatkan. Temuan ini menegaskan bahaya halusinasi yang tersembunyi di balik gaya bahasa yang meyakinkan dan tidak terdeteksi dari sisi relevansi bahasa saja, serta membuktikan peran RAG yang sangat vital dalam menyelaraskan jawaban model dengan kebijakan kesehatan nasional yang berlaku di Indonesia.

Secara keseluruhan, hasil pengujian menunjukkan bahwa arsitektur RAG yang dibangun, mencakup *knowledge base* 60 dokumen, indeks FAISS 12.558 *chunk*, *retrieval* MMR, hingga integrasi Qwen 2.5 7B Instruct, berjalan sesuai rancangan dan menghasilkan kinerja yang kuat pada seluruh enam metrik evaluasi, dengan *Answer Correctness* sebagai satu-satunya metrik yang secara struktural lebih rendah akibat perbedaan gaya elaborasi terhadap jawaban acuan pakar. Postur kinerja keseluruhan atas keenam metrik ditunjukkan pada Gambar 4.



Gambar 4. Postur kinerja RAG keseluruhan (agregat 6 metrik evaluasi)

4. PENUTUP

Implementasi RAG dengan generator Qwen 2.5 7B Instruct pada domain tanya jawab stunting berbahasa Indonesia telah berhasil direalisasikan melalui pipeline terintegrasi mulai dari persiapan *knowledge base* 60 dokumen hingga indeks FAISS berisi 12.558 *chunk*, dengan kuantisasi NF4 4-bit terbukti efisien dijalankan pada GPU T4 tanpa mengorbankan kemampuan model mengikuti instruksi dalam Bahasa Indonesia. Pengujian menggunakan *Gold Standard Dataset* menunjukkan kinerja yang kuat pada seluruh metrik evaluasi, dengan *MRR* mencapai sekitar 0,95 dan *Faithfulness* rata-rata sekitar 0,90 yang mengonfirmasi RAG secara signifikan menekan halusinasi dibandingkan skenario *No-RAG*, meskipun sistem masih menunjukkan kelemahan pada tipe pertanyaan *numerical* dengan *Faithfulness* turun hingga sekitar 0,69 akibat karakteristik data tabular yang sulit ditangani strategi *chunking* dan *retrieval* saat ini. Kekurangan ini membuka ruang penelitian lanjutan, di antaranya eksplorasi *parsing* tabel berbasis model visi-bahasa dan mekanisme *hybrid search* untuk memperbaiki *recall* pada data numerik dan pertanyaan lintas dokumen, perluasan volume dan pemutakhiran *knowledge base* secara berkala mengingat sifat *timeliness* dokumen kesehatan, pengujian langsung terhadap masyarakat dan tenaga kesehatan di luar data sintetis, penerapan uji ablasi dan ketahanan sistem terhadap variasi input, serta pengembangan lanjutan menjadi aplikasi produksi yang lebih skalabel guna memperluas jangkauan edukasi kesehatan stunting bagi masyarakat Indonesia.

UCAPAN TERIMA KASIH

Penulis mengucapkan terima kasih kepada seluruh pihak yang telah membantu terselesaikannya penelitian ini, terutama kepada dosen pembimbing dan pakar gizi atas bimbingan dan ketelitian yang menjaga penelitian ini tetap akurat. Terima kasih kepada keluarga atas dukungan yang tidak pernah putus, serta kepada seseorang yang selalu hadir di setiap prosesnya.

DAFTAR PUSTAKA

[1] T. Wahyuni, R. A, D. Sartika, M. Kusumaningrum, and M. A. Sari, “Implementasi Kebijakan Pemerintah Dalam Penurunan Prevalensi Stunting,” *J. Ris. Inossa Media Has. Ris. Pemerintahan, Ekon. dan Sumber Daya Alam*, vol. 6, no. 02, pp. 38–50, 2025, doi: 10.54902/jri.v6i02.161.

[2] Kemenkes RI, “Survei Status Gizi Indonesia 2024 Dalam Angka,” 2025. [Online]. Available: https://www.badankebijakan.kemkes.go.id/survei-status-gizi-indonesia-ssgi-2024/

[3] N. Nurhayati, N. Kurwiyah, R. Rohanah, S. D. Paramita, and A. D. Putri Atifa, “Keterpaparan informasi dan tingkat pengetahuan tentang stunting pada remaja putri,” *Holistik J. Kesehat.*, vol. 17, no. 8, pp. 688–696, 2023, doi: 10.33024/hjk.v17i8.12937.

[4] G. Samudra, A. T. Zy, and Ermanto, “Implementasi Retrieval Augmented Generation (RAG) Dalam Perancangan Chatbot Kesehatan Pencernaan,” *JSAI J. Sci. Appl. Informatics*, vol. 8, no. 1, pp. 1–8, 2025.

[5] D. Sarkar, “Navigating the Knowledge Sea: Planet-scale answer retrieval using LLMs,” *arXiv*, 2024, [Online]. Available: https://arxiv.org/abs/2402.05318

[6] S. H. Kumar *et al.*, “Cue-bot: A Conversational Agent for Assistive Technology,” in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, 2022, pp. 196–203. doi: 10.18653/v1/2022.acl-demo.19.

[7] L. K. Umapathi, M. Sankarasubbu, and A. Pal, “Med-HALT: Medical Domain Hallucination Test for Large Language Models,” *27th Conf. Comput. Nat. Lang. Learn. Proc.*, pp. 314–334, 2023, doi: https://dx.doi.org/10.18653/v1/2023.conll-1.21.

[8] V. Agarwal, Y. Jin, M. Chandra, M. De Choudhury, S. Kumar, and N. Sastry, “MEDHALU : Hallucinations in Responses to Healthcare Queries by Large Language Models,” *Proc. Twent. Int. AAAI Conf. Web Soc. Media*, vol. 20(1), no. Icwsm, pp. 31–44, 2026.

[9] M. Omar *et al.*, “Multi-model assurance analysis showing large language models are highly vulnerable to adversarial hallucination attacks during clinical decision support,” *Commun. Med.*, vol. 5, no. 1, pp. 1–7, 2025, doi: 10.1038/s43856-025-01021-3.

[10] Z. Li *et al.*, “Evaluating clinical competencies of large language models with a general practice benchmark,” *Nat. Commun.*, pp. 1–12, 2026.

[11] C. Garcia Fernandez, “Trustworthy AI for medicine: Continuous hallucination detection and elimination with CHECK,” *Ann. Oncol.*, vol. 36, p. S1654, 2025, doi: 10.1016/j.annonc.2025.08.457.

[12] S. Anjum, H. Zhang, W. Zhou, E. J. Paek, X. Zhao, and Y. Feng, “HALO: Hallucination Analysis

and Learning Optimization to Empower LLMs with Retrieval-Augmented Context for Guided Clinical Decision Making," in *Proceedings - 2025 IEEE/ACM International Conference on Connected Health: Applications, Systems and Engineering Technologies, CHASE 2025*, 2024, pp. 187–198. doi: 10.1145/3721201.3721385.

[13] A. Boulesnane and A. Souilah, "An Evolutionary Large Language Model for Hallucination Mitigation," in *Proceedings - ECTE-Tech 2024: International Conference on Electrical, Computer, Telecommunication, and Energy Technologies*, 2024. doi: 10.1109/ECTE-TECH62477.2024.10851107.

[14] Q. Wei, H. Ning, C. Han, and J. Ding, "A query-aware multi-path knowledge graph fusion approach for enhancing retrieval-augmented insgeneration in large language models," *Expert Syst. Appl.*, vol. 316, p. 131932, 2026, doi: https://doi.org/10.1016/j.eswa.2026.131932.

[15] Y. Wang, Y. Wan, X. Lei, Q. Chen, and H. Hu, "A retrieval augmented generation based optimization approach for medical knowledge understanding and reasoning in large language models," *Array*, vol. 28, no. September, p. 100504, 2025, doi: 10.1016/j.array.2025.100504.

[16] D. K. Pham and B. Q. Vo, "Towards Reliable Medical Question Answering: Techniques and Challenges in Mitigating Hallucinations in Language Models," 2024, [Online]. Available: http://arxiv.org/abs/2408.13808

[17] R. Adha, D. Syaripudin, B. K. S, A. M. Bachtiar, H. Maulana, and E. Rainarli, "Integrasi Gemini AI Berbasis Retrieval-Augmented Generation (RAG) pada Moodle untuk Penilaian Esai Otomatis dengan Pendekatan Human-in-the-Loop di Pendidikan Tinggi," *Acad. J. Comput. Sci. Res.*, vol. 8, no. 1, pp. 67–74, 2026.

[18] S. Cahyawijaya *et al.*, "Cendol: Open Instruction-tuned Generative Large Language Models for Indonesian Languages," in *Proceedings of the Annual Meeting of the Association for Computational Linguistics*, 2024, pp. 14899–14914. doi: 10.18653/v1/2024.acl-long.796.

[19] D. S. adillah Maylawati, Y. J. Kumar, F. B. Kasmin, and M. A. Ramdhani, "Readability Evaluation Metrics for Indonesian Automatic Text Summarization: A Systematic Review," 2024. doi: 10.25103/jestr.175.25.

[20] Qwen *et al.*, "Qwen2.5 Technical Report," 2025, [Online]. Available: https://arxiv.org/abs/2412.15115

[21] W. Christian, D. Adamlu, A. Yu, and D. Suhartono, "Bridging Language Gaps with Adaptive RAG: Improving Indonesian Language Question Answering," 2025, [Online]. Available: http://arxiv.org/abs/2510.21068

[22] A. Yang *et al.*, "Qwen2 Technical Report," pp. 1–26, 2024, [Online]. Available: https://arxiv.org/abs/2407.10671

[23] H. Lijaya, P. Ho, and H. Santoso, "Comparative Analysis of RAG-Based Open-Source LLMs for Indonesian Banking Customer Service Optimization Using Simulated Data," *J. Sisfokom (Sistem Inf. dan Komputer)*, vol. 14, no. 3, pp. 330–341, 2025, doi: 10.32736/sisfokom.v14i3.2383.

[24] D. Firdaus, I. Sumardi, and Y. Kulsum, "Integrating Retrieval-Augmented Generation with Large Language Model Mistral 7b for Indonesian Medical Herb," *JISKA (Jurnal Inform. Sunan Kalijaga)*, vol. 9, no. 3, pp. 230–243, 2024, doi: 10.14421/jiska.2024.9.3.230-243.

[25] K. S. Handoyo, M. L. Klau, R. J. Wijaya, and R. P. Kristianto, "Penerapan Retrieval-Augmented Generation untuk Pembuatan Soal Pilihan Ganda dari Materi Berbasis PDF," *Pros. Semin. Nas. KONSTELASI*, vol. 3, no. 1, pp. 200–209, 2026, doi: 10.24002/prosidingkonstelasi.v3i1.13516.

[26] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 Text Embeddings: A Technical Report," 2024, [Online]. Available: http://arxiv.org/abs/2402.05672

[27] Y. Choi, S. Kim, Y. Cedric, and F. Bassole, "Enhanced Retrieval-Augmented Generation Using Low-Rank Adaptation," *Appl. Sci.*, vol. 15, pp. 1–19, 2025.

[28] S. Es, J. James, L. Espinosa-Anke, and S. Schockaert, "RAGAS: Automated Evaluation of Retrieval Augmented Generation," in *EACL 2024 - 18th Conference of the European Chapter of the Association for Computational Linguistics, Proceedings of System Demonstrations*, 2024, pp. 150–158. doi: 10.18653/v1/2024.eacl-demo.16.